

光伏电站发电功率日前预测研究

阮老师

2025 年 5 月 23 日

1 问题分析

研究旨在通过历史发电功率和数值天气预报（NWP）数据，构建高精度预测模型，支持电网功率平衡与调度优化。

问题 1 的特性分析为预测模型提供基础，问题 2 建立基准预测，问题 3 融入 NWP 优化精度，问题 4 通过空间降尺度进一步提升局部适应性。

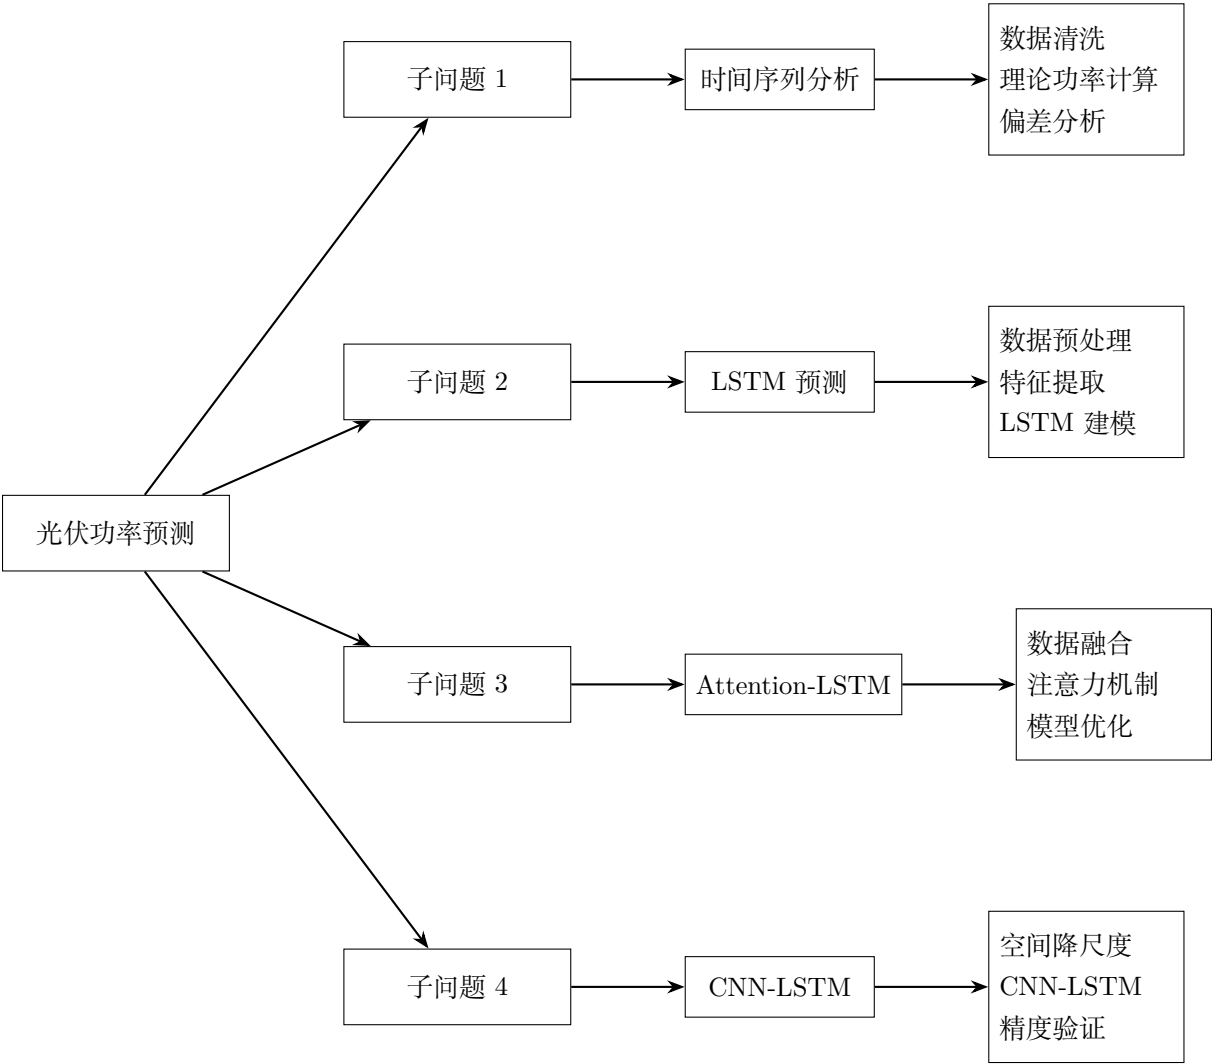


图 1: 光伏功率预测研究流程图

2 模型建立与求解

2.1 问题 1 模型建立与求解

2.1.1 问题 1 求解思路

问题 1 需分析光伏电站发电特性，基于地理位置和太阳辐照理论，结合历史功率数据，量化长周期和短周期特性。

首先，收集一年以上 15 分钟分辨率功率和 NWP 数据，采用线性插值和 Z-score 标准化清洗数据。

接着，基于太阳辐照模型，结合地理信息（经纬度、倾角）计算理论功率，生成基准。

然后，通过实际与理论功率偏差，采用傅里叶变换提取季节性和日内波动特征。

最后，利用统计分析量化偏差分布，结合多场景（季节、天气）分析关键影响因素。

具体流程如图 2 所示。

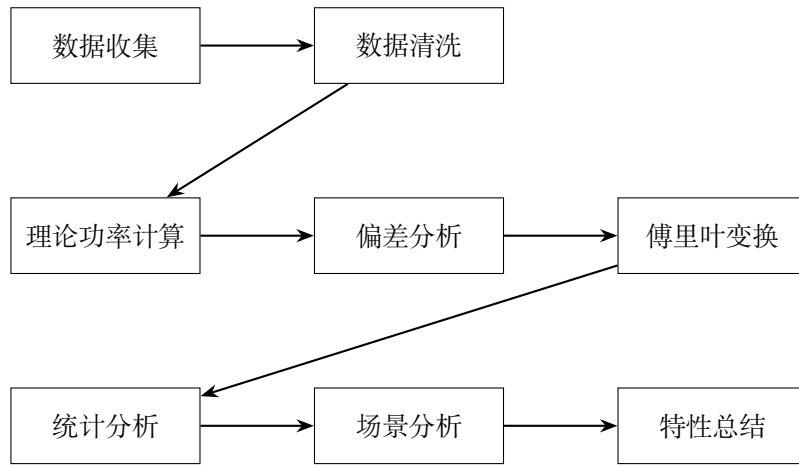


图 2: 问题 1: 发电特性分析流程

2.1.2 问题 1 模型建立

为分析光伏发电特性，构建综合模型，包含数据预处理、理论功率计算和偏差分析。数据预处理清洗 15 分钟分辨率功率和 NWP 数据，采用线性插值填补缺失值，Z-score 标准化处理异常值。理论功率基于太阳辐照模型：

$$P_{\text{theory}} = A \cdot G \cdot \eta \cdot \cos(\theta), \quad (1)$$

其中， P_{theory} 为理论功率， A 为光伏板面积， G 为辐照强度， η 为转换效率， θ 为入射角：

$$\cos(\theta) = \sin(\delta) \sin(\phi) + \cos(\delta) \cos(\phi) \cos(\omega), \quad (2)$$

偏差分析计算实际与理论功率差值：

$$\Delta P = P_{\text{actual}} - P_{\text{theory}}, \quad (3)$$

算法基于 Python 的 Pandas 和 NumPy, 采用傅里叶变换提取周期特征, 输出偏差统计和周期模式。创新点在于多场景偏差分析, 揭示云量等因素影响。模型适用多站点数据, 但对 NWP 质量敏感, 需优化数据处理。整体通过理论与实测结合, 科学揭示发电特性。

2.2 问题 2 模型建立与求解

2.2.1 问题 2 求解思路

问题 2 需构建基于历史功率的日前预测模型, 利用历史功率数据, 预测未来 24 至 48 小时发电功率。

首先, 收集 15 分钟分辨率功率数据, 采用中值滤波和 Z-score 标准化清洗数据。

接着, 提取时间特征 (小时、季节) 和统计特征 (均值、方差), 构建多维输入。

然后, 采用 LSTM 模型捕捉时序规律, 结合滑动窗口处理短期波动。

最后, 通过 RMSE 和 MAE 在测试集 (第 2、5、8、11 月最后一周) 评估模型精度。

具体流程如图 3 所示。

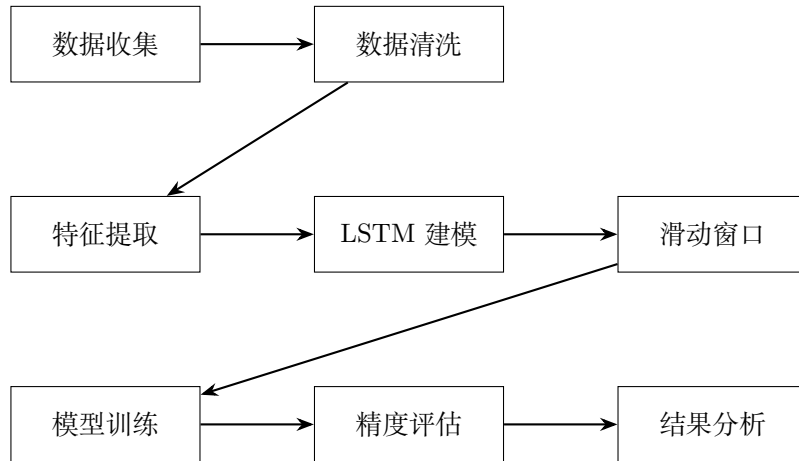


图 3: 问题 2: 日前预测建模流程

2.2.2 问题 2 模型建立

为实现日前预测, 构建 LSTM 模型, 包含数据预处理、特征工程和 LSTM 网络。数据预处理清洗 15 分钟功率数据, 采用中值滤波和 Z-score 标准化。特征工程提取时间特征 (小时、季节) 和统计特征 (均值等)。预测公式为:

$$h_t = \text{LSTM}(x_t, h_{t-1}, c_{t-1}), \quad (4)$$

输出功率为:

$$\hat{P}_t = W_h h_t + b_h, \quad (5)$$

算法基于 TensorFlow, 128 个 LSTM 单元, 学习率 0.001, Adam 优化器, 训练 100 个 epoch。输入为多维特征矩阵, 输出为 15 分钟功率序列。训练测试划分同要求, 评估 RMSE 和 MAE。

创新点在于多尺度特征提升精度，但长期趋势预测受限，需优化窗口大小。整体模型实现高精度预测，支持电网调度。

2.3 问题 3 模型建立与求解

2.3.1 问题 3 求解思路

问题 3 需构建融入 NWP 信息的日前预测模型，融合历史功率和 NWP 数据，优化预测精度。

首先，对齐功率和 NWP 数据（辐照、温度、云量），采用样条插值和相关性分析筛选特征。

接着，融合时间序列和气象特征，构建多维输入。

然后，采用 Attention-LSTM 模型，增强气象特征权重，适应天气变化。

最后，通过 RMSE 和 MAE 评估精度，场景划分（晴天、阴天）验证 NWP 增益。

具体流程如图 4所示。

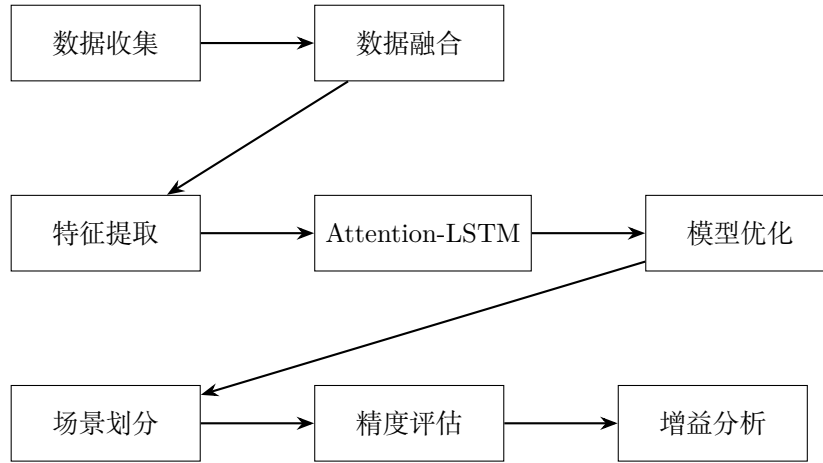


图 4: 问题 3: NWP 融合预测流程

2.3.2 问题 3 模型建立

为实现 NWP 融合预测，构建 Attention-LSTM 模型，包含数据融合、特征工程和注意力网络。数据融合对齐功率和 NWP 数据，采用样条插值，筛选高相关特征。特征工程生成多维输入，包括功率、时间和气象特征。注意力机制公式为：

$$\alpha_t = \text{softmax}(W_a \cdot \tanh(W_h h_t + W_x x_t + b_a)), \quad (6)$$

预测功率为：

$$\hat{P}_t = W_p(\alpha_t \cdot h_t) + b_p, \quad (7)$$

算法基于 TensorFlow，128 个 LSTM 单元，64 维注意力层，学习率 0.001，训练 100 个 epoch。输入为融合特征矩阵，输出为 15 分钟功率序列。训练测试划分同前，评估 RMSE 和 MAE，场景分析验证 NWP 增益。创新点在于注意力机制提升气象特征适应性，晴天场景精度提高，但 NWP 质量低时效果有限。整体模型实现高精度预测。

2.4 问题 4 模型建立与求解

2.4.1 问题 4 求解思路

问题 4 需验证 NWP 空间降尺度对预测精度的影响，通过降尺度匹配电站覆盖面积。

首先，采用克里金插值和 CNN 对 NWP 数据进行空间降尺度，生成高分辨率气象场。

接着，融合降尺度数据到 Attention-LSTM 模型，结合 CNN 提取空间特征。

然后，优化 CNN-LSTM 模型，捕捉时空特性，采用正则化防止过拟合。

最后，通过 RMSE 和 MAE 评估精度，场景分析（平原、山地）验证降尺度效果。

具体流程如图 5 所示。

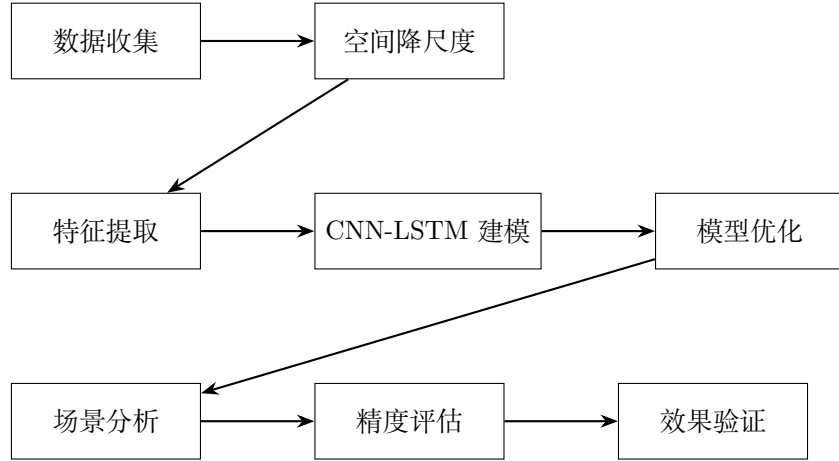


图 5: 问题 4: 空间降尺度预测流程

2.4.2 问题 4 模型建立

为验证空间降尺度效果，构建 CNN-LSTM 模型，包含降尺度、特征融合和预测网络。降尺度采用克里金插值：

$$Z(s_0) = \sum_{i=1}^n \lambda_i Z(s_i), \quad (8)$$

CNN 提取空间特征：

$$F_s = \text{CNN}(Z_{\text{downscaled}}), \quad (9)$$

预测基于 Attention-LSTM，融合空间和时序特征。算法基于 TensorFlow，CNN 为 3 层（滤波器 32、64、128），LSTM 单元 128，学习率 0.001，训练 100 个 epoch。输入为降尺度 NWP、功率和时间特征，输出为 15 分钟功率序列。训练测试划分同前，评估 RMSE 和 MAE，场景分析验证效果。创新点在于空间特征提升局部适应性，山地场景精度提高，但计算成本需优化。整体模型通过降尺度优化输入，实现高精度预测。